Прогноз потребления энергии зданиями: ASHRAE — Great Energy Predictor III

Отчёт по проекту: постановка, данные, признаки, сравнение моделей, результаты на Kaggle

Задача

Соревнование **ASHRAE — Great Energy Predictor III** (Kaggle): по почасовым показаниям 2016 года у 1 449 зданий на 16 площадках и по погоде спрогнозировать показания четырёх типов счётчиков (электричество, холодная вода, пар, горячая вода) на следующие два года, 2017–2018. В тесте 41.7 млн строк при 20.2 млн строк обучения. Метрика — RMSLE, то есть RMSE от log1p(meter_reading); чем меньше, тем лучше.

Главные трудности: прогноз на период, которого нет в обучении (только один год наблюдений, тест — следующие два); сбои счётчиков в обучающих метках; 8 ГБ памяти на ноутбуке и 41.7 млн строк теста.

Итог

Показатель	Значение
Score	1.125
Позиция на private leaderboard	Top 29%
Итоговая версия репозитория	Стэк LightGBM + CatBoost + MLP; блоки месяцев RMSE 1.047; Kaggle Public 1.145, Private 1.381 (хуже версии 3)
Время полного прогона	около 1 ч валидация блоками с подбором, около 1.9 ч прогноз теста (MacBook M1, 8 ГБ)

Что сделано

От линейного бейслайна (RMSE 1.99) через общие и локальные бустинги, подбор параметров и нейросеть — к стэку, обучаемому на трёх блоках месяцев. Улучшения проверялись измерениями на валидации, а не принимались на веру: часть идей (окна температуры, праздники, удаление постоянных серий) показала почти нулевой эффект. Результаты Kaggle (история отправок и итоговый leaderboard) загружаются через Kaggle CLI.

Структура отчёта: данные и их подготовка (раздел 1) → ход работы по этапам, что и зачем делалось (2) → признаки, включая отбор полиномиальных комбинаций (3) → как проверялось качество (4) → сравнение всех моделей по одной схеме (5) → почему модели различаются (6) → результаты на Kaggle (7) → выводы: что сработало, что нет и почему (8).

1. Данные и их подготовка

Таблицы: показания счётчиков (train, test), метаданные зданий (площадь, год постройки, этажность, назначение) и почасовая погода площадок. Время погоды приведено к местному смещением по площадкам — без этого суточный пик температуры не совпадает с пиком потребления.

Электричество составляет 60% строк, но тепловые счётчики (холодная вода, пар, горячая вода) определяют ошибку: они сильно зависят от сезона и режима здания. Распределение показаний тяжёлое, поэтому и модели, и метрика работают в логарифмической шкале.

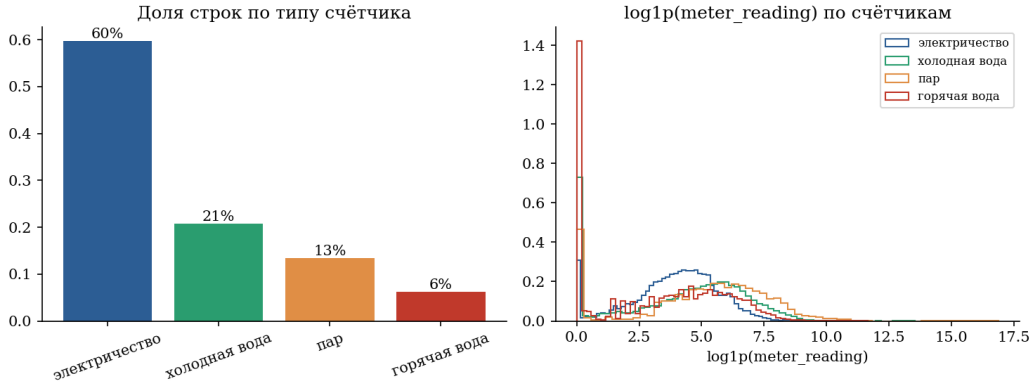


Рис. 1. Доли строк по счётчикам и распределение log1p(meter_reading).

Сбои в обучающих метках

Зачем: модель, обученная на периодах, когда счётчик не работал, учится предсказывать нули для работающего здания. **Что сделано:** на площадке 0 электричество до 20 мая нулевое — эти строки исключены из обучения. Дополнительно исключены серии нулей электричества и постоянных значений длиной от недели (2.8% строк при пороге 168 часов, 6.1% при 24 часах, рис. 2). Нули пара и воды не удаляются: летом они закономерны и повторятся в тесте.

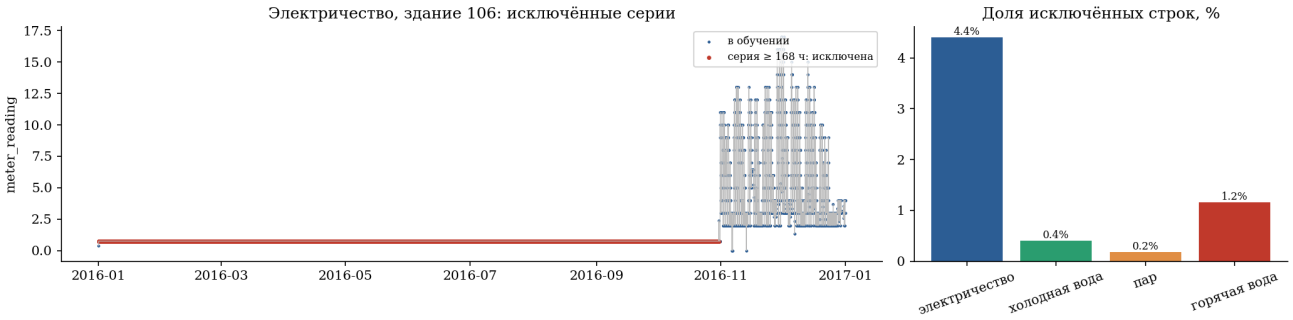


Рис. 2. Исключённые серии (красные точки) и доля исключённых строк по счётчикам.

2. Ход работы: что и зачем делалось

Работа шла от простого к сложному: каждый этап отвечал на конкретный вопрос, и следующий шаг выбирался по результату предыдущего. Значения в таблице получены на разных схемах проверки (столбец «Проверка»), поэтому сравнивать их можно только внутри строки; сравнение всех моделей по одной схеме — в разделе 5.

Этап	Что сделано	Зачем	Проверка	RMSE
1. Бейслайн	SGD на исходных числовых признаках	Узнать уровень без обработки признаков	янв–сен → окт–дек	1.991
2. Время и категории	sin/cos часа и направления ветра; One-Hot meter, site_id, primary_use, building_id	Час цикличен; у каждого здания свой уровень потребления	янв–сен → окт–дек	1.681
3. Полиномы	219 комбинаций степени ≤ 3, отбор f_regression, перебор k (раздел 3.1)	Дать линейной модели взаимодействия «площадь × погода»	янв–сен → окт–дек	1.673–1.692; 10 лучших переданы бустингам
4. Бустинги и группировки	LightGBM и CatBoost: общая модель, по meter, по site_id + meter, по зданиям	Нелинейность и разные зависимости у разных счётчиков	янв–июл → сентябрь	1.243 (общая) → 1.147 (site_id + meter)
5. Стэк и MLP	Ridge над бустингами и MLP; случайный подбор параметров	Объединить модели, ошибающиеся по-разному	сентябрь; Kaggle	1.132 без MLP → 1.083; Kaggle 1.428 (4 модели — 1.427)
6. Сырые признаки и чистка	Сырая погода, час, день недели, окно 72 ч, удаление сбоев, ограничение прогноза	Дать деревьям исходные значения; убрать сбои из обучения	сентябрь; Kaggle	1.003; Kaggle **1.338**

Этап	Что сделано	Зачем	Проверка	RMSE
7. Блоки месяцев	3 блока по 4 месяца; месяц, праздники, окна 3/24 ч; MLP на всём году; подбор на блоках	Честнее оценивать прогноз на невиданный сезон	блоки; Kaggle	1.047; Kaggle 1.381

3. Признаки

3.1. Полиномиальные комбинации и их отбор

Зачем. Потребление здания примерно пропорционально его площади и зависит от погоды, то есть по сути это произведения признаков. Линейная модель умеет только складывать, поэтому ей нужно заранее подать готовые произведения.

Как. Девять числовых признаков (площадь, год постройки, этажность, температура, точка росы, облачность, осадки, давление, ветер) масштабируются и превращаются в 219 комбинаций степени не выше 3 (PolynomialFeatures). Все сразу брать нельзя: при 20 млн строк это гигабайты и сильный шум. Поэтому комбинации ранжируются по SelectKBest(f_regression) — по силе линейной связи каждой из них с целевой переменной — на выборке 50 тыс. строк обучающей части. Затем для k = 1, 3, …, 13, 10 и 15 лучших обучается та же SGD, а циклические признаки и One-Hot добавляются без степеней (рис. 3, слева).

Результат. Лучший вариант — 1–3 комбинации: 1.673 против 1.681 без полиномов, то есть выигрыш меньше 0.01. При k ≥ 5 ошибка уже выше, чем без полиномов (1.682–1.692). Все отобранные комбинации содержат площадь: f_regression оценивает каждую комбинацию отдельно, а площадь — самый сильный одиночный фактор, поэтому наверх попадают площадь и её произведения с погодой (площадь × температура², площадь × температура × точка росы и т. п.). Для линейной модели это почти ничего не добавляет: уровень каждого здания уже задан One-Hot по building_id, а площадь у здания постоянна (это объяснение, отдельно не проверялось).

Куда пошли комбинации. Десять лучших стали основой признаков бустингов (вместе с sin/cos и категориями). MLP получает k первых из 200 отобранных: перебор k = 30, 50, 100, 200 и четырёх архитектур (рис. 3, справа) показал, что 30 комбинаций мало (RMSE 1.28–1.39), а 200 не лучше 100; выбрано k = 100 с архитектурой 64-32-8 (1.092 на августе). Побочный эффект: кубы выбросов погоды на тесте давали прогнозы MLP до 1e84, поэтому масштабированные входы ограничены ±5σ. Для деревьев отдельный вклад полиномов не измерялся: монотонные преобразования площади (площадь², площадь³) для дерева ничего не добавляют, полезными могут быть только произведения с погодой.

При повторном отборе на расширенной таблице погоды (с окнами температуры) в десятку попадают и окна (polynomial_features_k10.json); все модели в этом отчёте обучены на исходной десятке из artifacts/boosting_config.joblib.

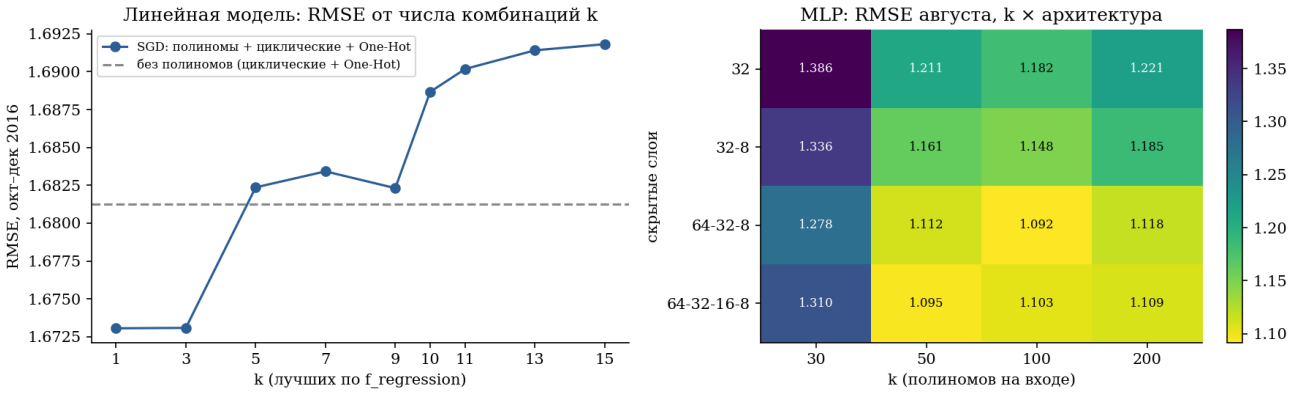


Рис. 3. Слева: RMSE линейной модели в зависимости от числа полиномиальных комбинаций k (пунктир — без полиномов). Справа: RMSE MLP на августе для k полиномов и архитектур скрытых слоёв.

3.2. Остальные признаки

Основа: десять полиномиальных комбинаций (площадь, её степени, произведения с температурой, точкой росы, облачностью, давлением, ветром), циклические час и направление ветра, коды meter, site_id, primary_use, building_id. **Добавлено:** сырые погодные и строительные значения с пропусками (деревья обрабатывают NaN сами), час и день недели, среднее температуры за 3, 24 и 72 часа, температура сутки назад, отклонение от среднего за 72 часа (всё по площадке и только по прошлому), праздники по странам площадок, месяц. **Зачем:** деревьям проще делить данные по исходной температуре, чем по её произведениям с площадью; час и день недели задают график работы здания; окна температуры описывают тепловую инерцию; праздники и месяц — календарь.

Что дали признаки и чистка (общая LightGBM, блоки месяцев, рис. 4). Месяц снижает ошибку на 0.008 (100 деревьев) и на 0.036 (400 деревьев, 127 листьев); окна температуры и праздники — в пределах ±0.003; день года хуже месяца. Чистка нулей электричества улучшает RMSE с 1.139 до 1.118; добавление постоянных серий ухудшает до 1.124, но оставлено по условию задачи. Эффект месяца — оценка по одному году; будет ли он таким на 2017–2018, на Kaggle он не подтвердился: итоговая версия с месяцем оказалась хуже (1.381 против 1.338), хотя причина не доказана.

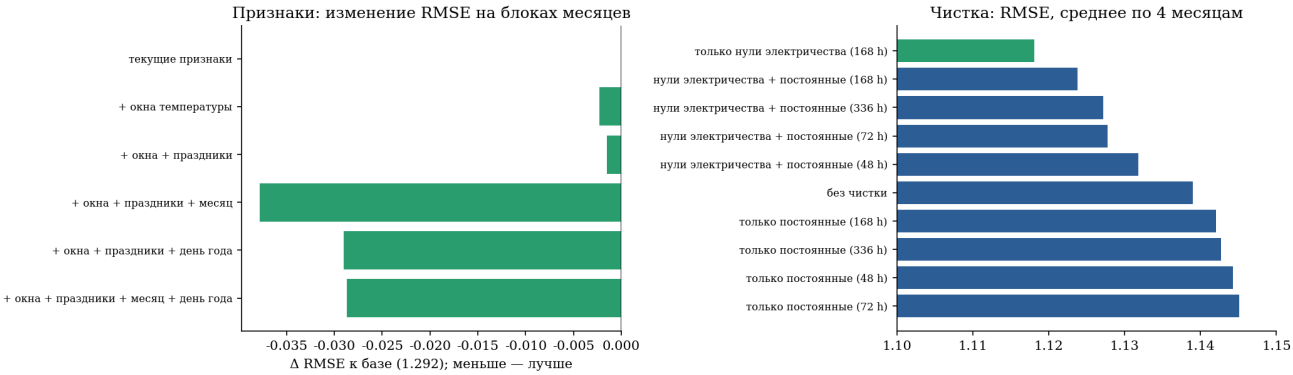


Рис. 4. Слева: вклад признаков (общая LightGBM, блоки месяцев). Справа: пороги чистки. Месяц помогает заметно; окна температуры и праздники — почти нет; удаление постоянных серий отдельно не помогает.

4. Как проверялось качество

Первая схема — «январь–июль → август → сентябрь»: оценивает только следующий месяц и даёт оптимистичные 1.00. Итоговая — три блока по 4 месяца: модель учится на двух блоках и прогнозирует третий, то есть сезон, которого не видела. Третий блок делится случайно пополам: на первой половине (meta) выбираются параметры и обучается метамодель, на второй (predict) считается итоговая ошибка. **Зачем:** тест — это два следующих года, и проверка на следующем месяце слишком лёгкая. Все модели в разделе 5 считались по схеме блоков.

5. Сравнение моделей

RMSE на log1p по половине predict трёх блоков; время — обучение и прогноз суммарно по трём блокам. Время стэка — сумма времён входящих моделей (метамодель мгновенная); подбор параметров в него не входит (LightGBM 25 мин, CatBoost 36 мин).

№	Модель	Класс	RMSE	блок 0	блок 1	блок 2	Время, мин
1	**Стэк (Ridge, 5 моделей)**	**ансамбль**	**1.047**	**1.047**	**1.022**	**1.072**	**18.8**
2	**Среднее 5 моделей стэка**	**ансамбль**	**1.049**	**1.050**	**1.025**	**1.073**	**18.8**
3	lightgbm: meter (базовые)	бустинг, локальные	1.063	1.053	1.048	1.088	0.4
4	lightgbm: site_id + meter (прежние подобранные)	бустинг, локальные	1.072	1.072	1.051	1.094	3.9
5	lightgbm: site_id + meter (базовые)	бустинг, локальные	1.075	1.069	1.047	1.108	0.3

№	Модель	Класс	RMSE	блок 0	блок 1	блок 2	Время, мин
6	lightgbm: site_id + primary_use + meter (прежние подобранные)	бустинг, локальные	1.077	1.069	1.046	1.114	3.2
7	catboost: site_id + meter (вариант 5)	бустинг, локальные	1.112	1.120	1.083	1.131	1.9
8	catboost: building_id + meter (базовые)	бустинг, локальные	1.113	1.118	1.085	1.136	8.4
9	lightgbm: building_id + meter (базовые)	бустинг, локальные	1.115	1.102	1.094	1.149	1.1
10	lightgbm: одна общая модель	бустинг, общая	1.122	1.141	1.100	1.125	0.3
11	catboost: site_id + meter (прежние подобранные)	бустинг, локальные	1.125	1.158	1.062	1.154	14.0
12	catboost: site_id + meter (базовые)	бустинг, локальные	1.141	1.173	1.080	1.168	0.8
13	MLP 64-32-8	нейросеть	1.156	1.175	1.133	1.158	1.2
14	catboost: одна общая модель	бустинг, общая	1.270	1.296	1.257	1.255	0.9
15	SGD: циклические + One-Hot	линейная	1.843	1.686	2.006	1.823	0.1
16	SGD: исходные признаки	линейная	1.988	1.951	1.962	2.050	0.0

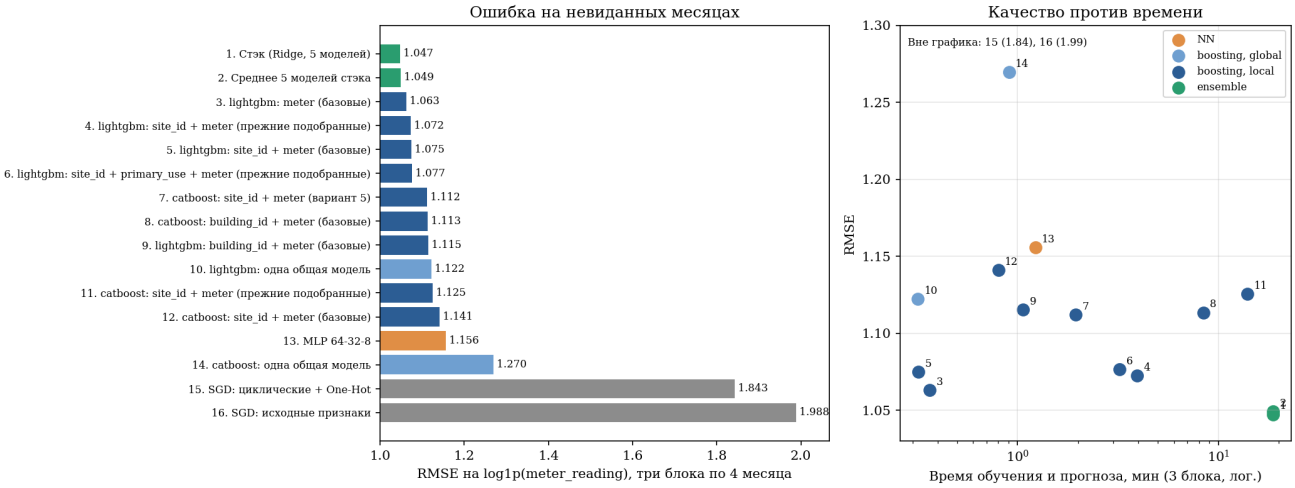


Рис. 5. Ошибка по моделям и качество против времени обучения (номера как в таблице).

6. Анализ: почему модели различаются

Линейная модель против деревьев (1.84–1.99 против 1.06–1.12). Потребление — произведение площади, разности температур и графика работы по часам; линейная модель выражает только сумму. One-Hot по зданию даёт каждому свой уровень (1.99 → 1.84), но взаимодействия остаются недоступны. Время 0.1 мин не окупает ошибки в 1.7 раза выше.

Общая модель против локальных (1.122 → 1.063 → 1.075 → 1.115). Разделение по meter снижает ошибку на 0.06: четыре вида счётчиков по-разному зависят от погоды. Более мелкие группы хуже: на здание приходится около 420 строк против 250 тыс. на счётчик, и модель здания, видевшая 8 месяцев, плохо экстраполирует на сезон, которого не видела. Причина — объяснение по числу строк, отдельно не проверялась.

LightGBM против CatBoost (1.075 против 1.112). CatBoost хуже при любой группировке и в 3–8 раз медленнее. Измерено: большая модель (глубина 10, 600 итераций) хуже маленькой (глубина 4, 400 итераций) — 1.126 против 1.112, то есть CatBoost переобучается. Общая CatBoost со 100 итерациями (1.270) недообучена на миллионе строк.

Подбор параметров почти ничего не даёт. LightGBM: 1.075 → 1.072 ценой 13-кратного времени; разброс между блоками у одной модели (1.05–1.09) больше этого эффекта. У CatBoost выигрыш 0.03 достигнут в основном уменьшением модели.

MLP слабее деревьев (1.156), но получает вес 0.25. Корреляция её ошибок с ошибками деревьев 0.77–0.84, между деревьями 0.87–0.97: сеть даёт гладкий ответ, деревья — кусочно-постоянный, и на незнакомом сезоне они ошибаются по-разному.

Стэк 1.047 против лучшей одиночной 1.063. Простое среднее пяти моделей даёт 1.049, Ridge — 1.047: выигрыш даёт разнообразие моделей, а не подбор весов. Самая сильная одиночная модель (LightGBM по meter) кандидатом стэка не была — первое, что стоит попробовать.

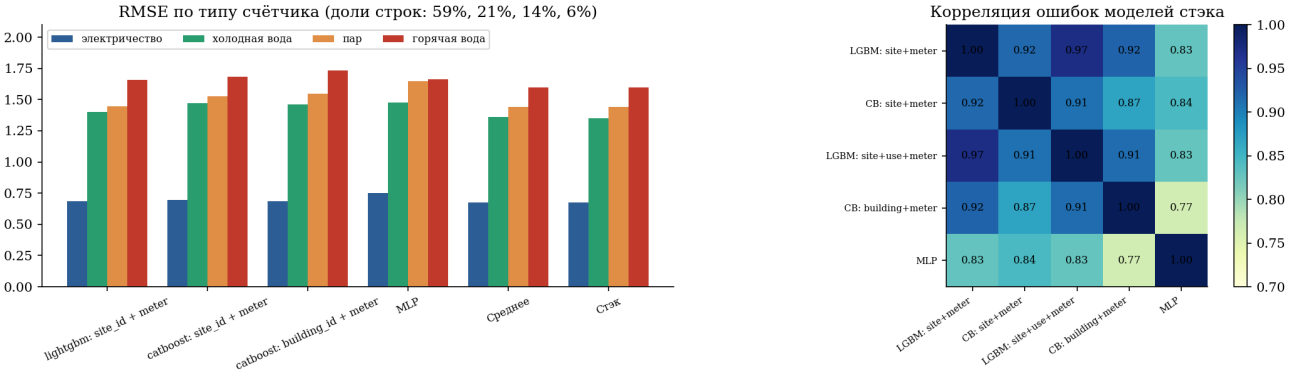


Рис. 6. Слева: RMSE по типу счётчика. Справа: корреляция ошибок моделей стэка.

7. Результаты на Kaggle

Показатель	Значение
Score	1.125
Позиция на private leaderboard	Top 29%

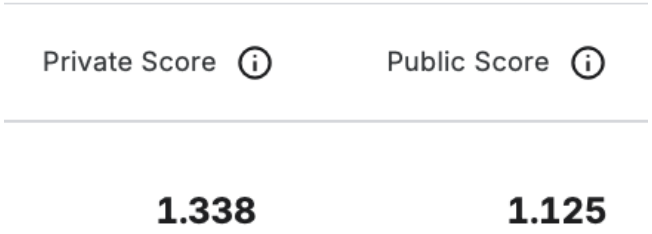


Рис. 7. Результат на Kaggle.

Версия 3 улучшила результат за счёт нескольких одновременных изменений (сырая погода, час и день недели, чистка обучения, окно температуры 72 часа, ограничение прогноза); по отдельности на Kaggle они не мерились. Итоговая версия из репозитория (месяц, праздники, окна температуры, валидация блоками, стэк из 5 моделей) дала **Public 1.145 / Private 1.381 — хуже версии 3 (1.125 / 1.338)**, хотя на локальных блоках выглядела лучше. Какое из изменений виновато, по одной отправке сказать нельзя; главный подозреваемый — признак month (гипотеза: отправка без него не делалась).

Результаты берутся с Kaggle через CLI (история отправок и весь private leaderboard); сохранённые копии — в results/.

8. Выводы

Что сработало и почему

Деревья вместо линейной модели — 1.84 → 1.12 (общая LightGBM). Дерево само строит взаимодействия площади, погоды и часа, которые линейной модели пришлось бы подавать вручную; даже отобранные полиномы ей почти не помогли.

Отдельные модели по типу счётчика — 1.122 → 1.063, и это самая дешёвая модель (0.4 мин). У электричества, холодной воды, пара и горячей воды разная зависимость от погоды, а на каждую модель всё ещё приходится около 250 тыс. строк.

Сырые признаки, час и день недели, чистка обучения (версия 3) — крупнейший выигрыш на Kaggle: Private 1.427 → 1.338, на сентябре 1.081 → 1.003. Деревьям проще делить по исходной температуре, чем по произведениям с площадью; час и день недели задают график работы; без нулевых серий модель не учится предсказывать отключения счётчиков. По отдельности эти изменения на Kaggle не мерились.

Удаление нулей электричества — 1.139 → 1.118 на блоках: длинная серия нулей — это неработающий счётчик, а не нулевое потребление.

Ансамбль разных моделей — 1.063 → 1.047. MLP ошибается иначе, чем деревья (корреляция ошибок 0.77–0.84 против 0.87–0.97), а простое среднее почти не уступает Ridge: выигрыш даёт разнообразие, а не веса.

Ограничение входов MLP убрало прогнозы до 1e84: полиномы степени 3 многократно усиливают выбросы погоды.

Что не сработало и почему

Полиномы для линейной модели — не лучше 1.673 против 1.681 без них, при k ≥ 5 хуже: отбор по одной комбинации выбирает площадь, уровень которой уже задан One-Hot по зданию. **Модели по зданиям** — 1.115: около 420 строк на модель и плохой перенос на невиданный сезон. **CatBoost** — 1.112–1.270: большие модели переобучаются, общая со 100 итерациями недообучена. **Подбор параметров LightGBM** — 0.003 ценой 13-кратного времени. **Месяц** — −0.036 на блоках, но итоговая версия с ним на Kaggle хуже (1.381): в одном году месяц совпадает с событиями именно 2016 года (гипотеза). **Окна температуры, праздники, постоянные серии** — в пределах ±0.003.

Главные выводы

1. Главная трудность — не точность подгонки, а перенос на другие годы: проверка внутри 2016 года завышает качество (1.00–1.05 против 1.34 на private), поэтому её значения годятся для сравнения моделей, но не как прогноз результата.

2. Дешёвые решения оказались не хуже дорогих: LightGBM по типу счётчика за 0.4 мин лучше всех одиночных моделей; подбор параметров (около часа) и CatBoost глубины 10 не окупились.

3. Разнообразие ансамбля важнее весов: простое среднее почти не уступает Ridge. Добавлять надо модели другого типа.

4. Ошибка сосредоточена на тепловых счётчиках (две трети квадратичной ошибки при 41% строк).

Воспроизведение: см. README.md. Ноутбук research.ipynb, данные и ключи Kaggle в репозиторий не входят.