Прогноз потребления энергии зданиями: ASHRAE — Great Energy Predictor III

Отчёт по проекту: постановка, данные, признаки, сравнение моделей, результаты на Kaggle

Задача

Соревнование **ASHRAE — Great Energy Predictor III** (Kaggle): по почасовым показаниям 2016 года у 1 449 зданий на 16 площадках и по погоде спрогнозировать показания четырёх типов счётчиков (электричество, холодная вода, пар, горячая вода) на следующие два года, 2017–2018. В тесте 41.7 млн строк при 20.2 млн строк обучения. Метрика — RMSLE, то есть RMSE от log1p(meter_reading); чем меньше, тем лучше.

Главные трудности: прогноз на период, которого нет в обучении (только один год наблюдений, тест — следующие два); сбои счётчиков в обучающих метках; 8 ГБ памяти на ноутбуке и 41.7 млн строк теста.

Итог

Показатель	Значение
Score	1.125
Позиция на private leaderboard	Top 29%
Итоговая версия репозитория	Стэк LightGBM + CatBoost + MLP; блоки месяцев RMSE 1.047; Kaggle Public 1.145, Private 1.381 (хуже версии 3)
Время полного прогона	около 1 ч валидация блоками с подбором, около 1.9 ч прогноз теста (MacBook M1, 8 ГБ)

Что сделано

От линейного бейслайна (RMSE 1.99) через общие и локальные бустинги, подбор параметров и нейросеть — к стэку, обучаемому на трёх блоках месяцев. Улучшения проверялись измерениями на валидации, а не принимались на веру: часть идей (окна температуры, праздники, удаление постоянных серий) показала почти нулевой эффект и в отчёте описана именно так. Результаты Kaggle (история отправок и итоговый leaderboard) загружаются через Kaggle CLI.

1. Данные и их особенности

Таблицы: показания счётчиков (train, test), метаданные зданий (площадь, год постройки, этажность, назначение) и почасовая погода площадок. Время погоды приведено к местному смещением по площадкам — без этого суточный пик температуры не совпадает с пиком потребления.

Электричество составляет 60% строк, но тепловые счётчики (холодная вода, пар, горячая вода) определяют ошибку: они сильно зависят от сезона и режима здания. Распределение показаний тяжёлое, поэтому и модели, и метрика работают в логарифмической шкале.

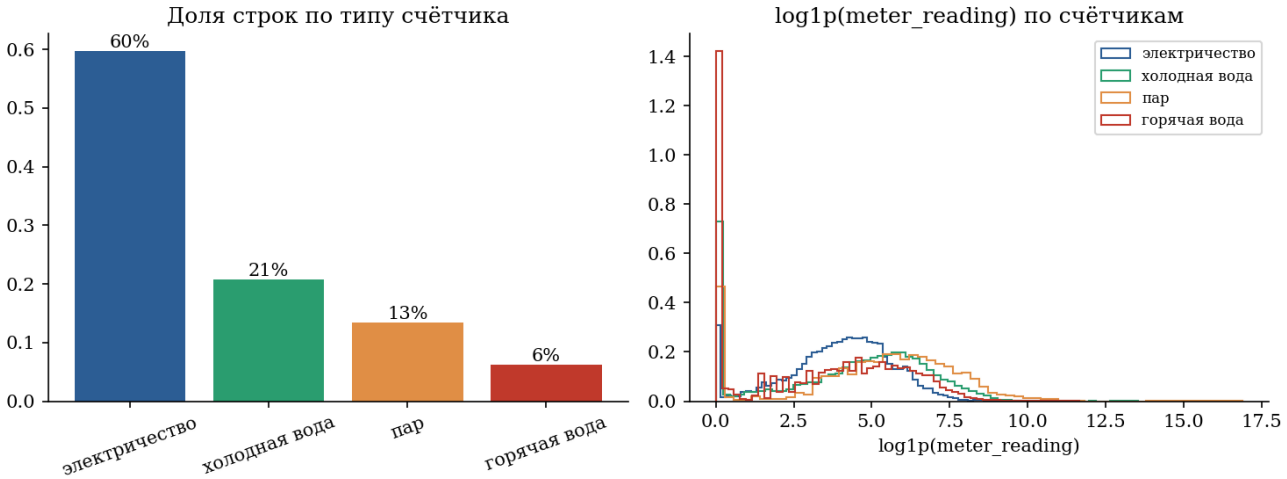


Рис. 1. Доли строк по счётчикам и распределение log1p(meter_reading).

Сбои в обучающих метках

Известный дефект: на площадке 0 электричество до 20 мая нулевое — эти строки исключены из обучения. Дополнительно исключены серии нулей электричества и постоянных значений длиной от недели (2.8% строк при пороге 168 часов, 6.1% при 24 часах, рис. 2). Нули пара и воды не удаляются: летом они закономерны и повторятся в тесте.

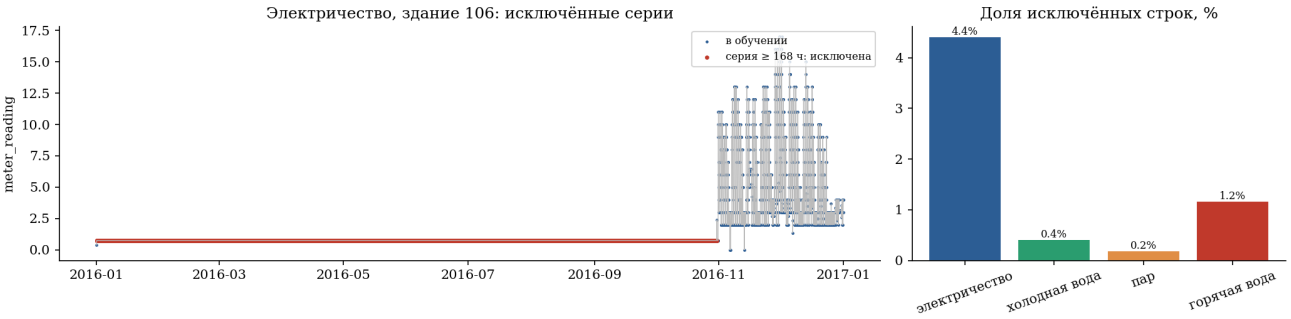


Рис. 2. Исключённые серии (красные точки) и доля исключённых строк по счётчикам.

2. Признаки и протокол проверки

Признаки

Основа: десять полиномиальных комбинаций (площадь, её степени, произведения с температурой, точкой росы, облачностью, давлением, ветром), циклические час и направление ветра, коды meter, site_id, primary_use, building_id. **Добавлено:** сырые погодные и строительные значения с пропусками (деревья обрабатывают NaN сами), час и день недели, среднее температуры за 3, 24 и 72 часа, температура сутки назад, отклонение от среднего за 72 часа (всё по площадке и только по прошлому), праздники по странам площадок, месяц.

Протокол

Первая схема — «январь–июль → август → сентябрь»: оценивает только следующий месяц и даёт оптимистичные 1.00. Итоговая — три блока по 4 месяца: модель учится на двух блоках и прогнозирует третий, то есть сезон, которого не видела. Третий блок делится случайно пополам: на первой половине (meta) выбираются параметры и обучается метамодель, на второй (predict) считается итоговая ошибка. Все модели в таблице ниже считались по этой схеме.

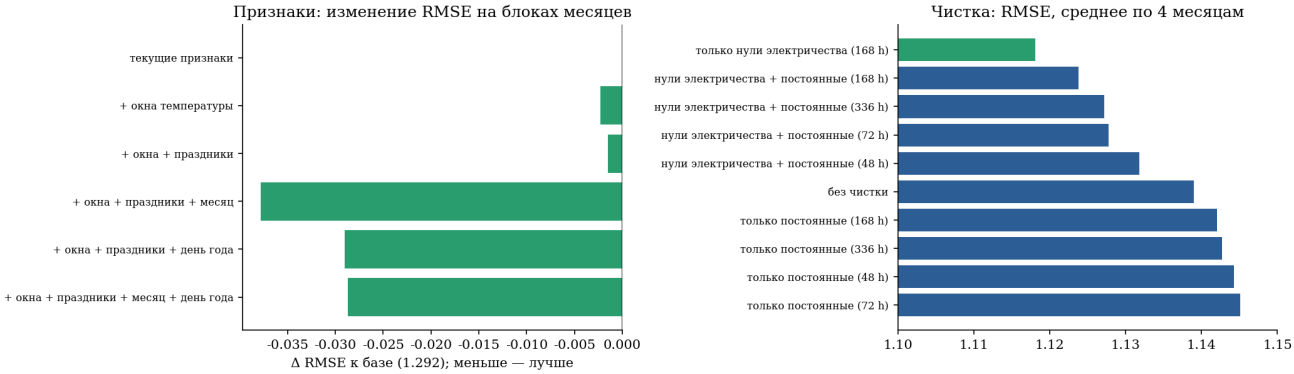


Рис. 3. Слева: вклад признаков (общая LightGBM, блоки месяцев). Справа: пороги чистки. Месяц помогает заметно; окна температуры и праздники — почти нет; удаление постоянных серий отдельно не помогает.

Что дали признаки и чистка (общая LightGBM, блоки месяцев)

Месяц снижает ошибку на 0.008 (100 деревьев) и на 0.036 (400 деревьев, 127 листьев); окна температуры и праздники — в пределах ±0.003; день года хуже месяца. Чистка нулей электричества улучшает RMSE с 1.139 до 1.118; добавление постоянных серий ухудшает до 1.124, но оставлено по условию задачи. Эффект месяца — оценка по одному году; будет ли он таким на 2017–2018, на Kaggle он не подтвердился: итоговая версия с месяцем оказалась хуже (1.381 против 1.338), хотя причина не доказана.

3. Сравнение моделей

RMSE на log1p по половине predict трёх блоков; время — обучение и прогноз суммарно по трём блокам. Время стэка — сумма времён входящих моделей (метамодель мгновенная); подбор параметров в него не входит (LightGBM 25 мин, CatBoost 36 мин).

№	Модель	Класс	RMSE	блок 0	блок 1	блок 2	Время, мин
1	**Стэк (Ridge, 5 моделей)**	**ансамбль**	**1.047**	**1.047**	**1.022**	**1.072**	**18.8**
2	**Среднее 5 моделей стэка**	**ансамбль**	**1.049**	**1.050**	**1.025**	**1.073**	**18.8**
3	lightgbm: meter (базовые)	бустинг, локальные	1.063	1.053	1.048	1.088	0.4
4	lightgbm: site_id + meter (прежние подобранные)	бустинг, локальные	1.072	1.072	1.051	1.094	3.9
5	lightgbm: site_id + meter (базовые)	бустинг, локальные	1.075	1.069	1.047	1.108	0.3
6	lightgbm: site_id + primary_use + meter (прежние подобранные)	бустинг, локальные	1.077	1.069	1.046	1.114	3.2
7	catboost: site_id + meter (вариант 5)	бустинг, локальные	1.112	1.120	1.083	1.131	1.9
8	catboost: building_id + meter (базовые)	бустинг, локальные	1.113	1.118	1.085	1.136	8.4
9	lightgbm: building_id + meter (базовые)	бустинг, локальные	1.115	1.102	1.094	1.149	1.1
10	lightgbm: одна общая модель	бустинг, общая	1.122	1.141	1.100	1.125	0.3
11	catboost: site_id + meter (прежние подобранные)	бустинг, локальные	1.125	1.158	1.062	1.154	14.0
12	catboost: site_id + meter (базовые)	бустинг, локальные	1.141	1.173	1.080	1.168	0.8
13	MLP 64-32-8	нейросеть	1.156	1.175	1.133	1.158	1.2
14	catboost: одна общая модель	бустинг, общая	1.270	1.296	1.257	1.255	0.9
15	SGD: циклические + One-Hot	линейная	1.843	1.686	2.006	1.823	0.1
16	SGD: исходные признаки	линейная	1.988	1.951	1.962	2.050	0.0

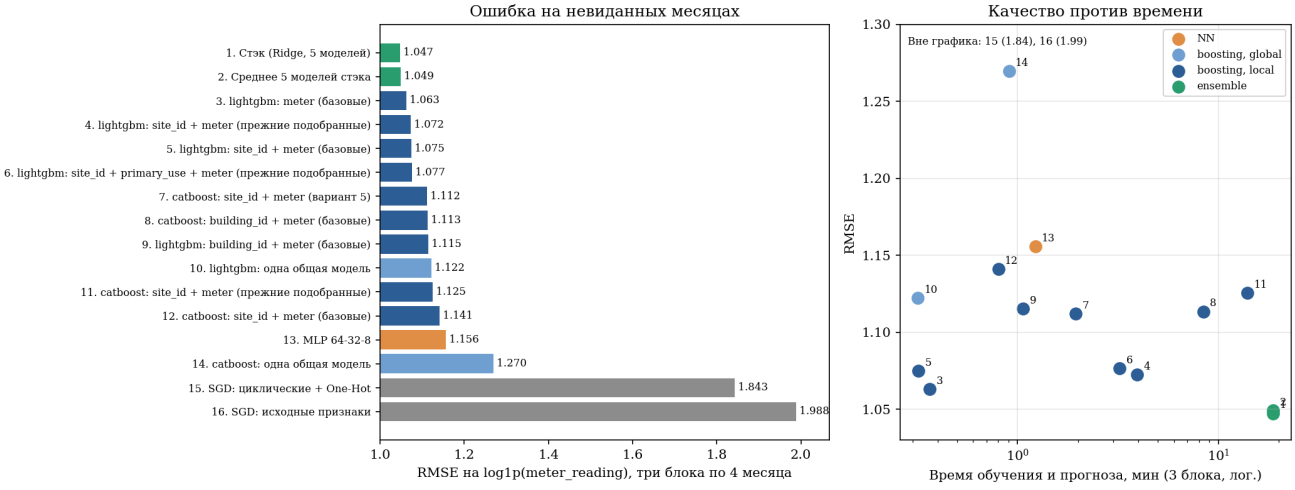


Рис. 4. Ошибка по моделям и качество против времени обучения (номера как в таблице).

4. Анализ: почему модели различаются

Линейная модель против деревьев (1.84–1.99 против 1.06–1.12). Потребление — произведение площади, разности температур и графика работы по часам; линейная модель выражает только сумму. One-Hot по зданию даёт каждому свой уровень (1.99 → 1.84), но взаимодействия остаются недоступны. Время 0.1 мин не окупает ошибки в 1.7 раза выше.

Общая модель против локальных (1.122 → 1.063 → 1.075 → 1.115). Разделение по meter снижает ошибку на 0.06: четыре вида счётчиков по-разному зависят от погоды. Более мелкие группы хуже: на здание приходится около 420 строк против 250 тыс. на счётчик, и модель здания, видевшая 8 месяцев, плохо экстраполирует на сезон, которого не видела. Причина — объяснение по числу строк, отдельно не проверялась.

LightGBM против CatBoost (1.075 против 1.112). CatBoost хуже при любой группировке и в 3–8 раз медленнее. Измерено: большая модель (глубина 10, 600 итераций) хуже маленькой (глубина 4, 400 итераций) — 1.126 против 1.112, то есть CatBoost переобучается. Общая CatBoost со 100 итерациями (1.270) недообучена на миллионе строк.

Подбор параметров почти ничего не даёт. LightGBM: 1.075 → 1.072 ценой 13-кратного времени; разброс между блоками у одной модели (1.05–1.09) больше этого эффекта. У CatBoost выигрыш 0.03 достигнут в основном уменьшением модели.

MLP слабее деревьев (1.156), но получает вес 0.25. Корреляция её ошибок с ошибками деревьев 0.77–0.84, между деревьями 0.87–0.97: сеть даёт гладкий ответ, деревья — кусочно-постоянный, и на незнакомом сезоне они ошибаются по-разному.

Стэк 1.047 против лучшей одиночной 1.063. Простое среднее пяти моделей даёт 1.049, Ridge — 1.047: выигрыш даёт разнообразие моделей, а не подбор весов. Самая сильная одиночная модель (LightGBM по meter) кандидатом стэка не была — первое, что стоит попробовать.

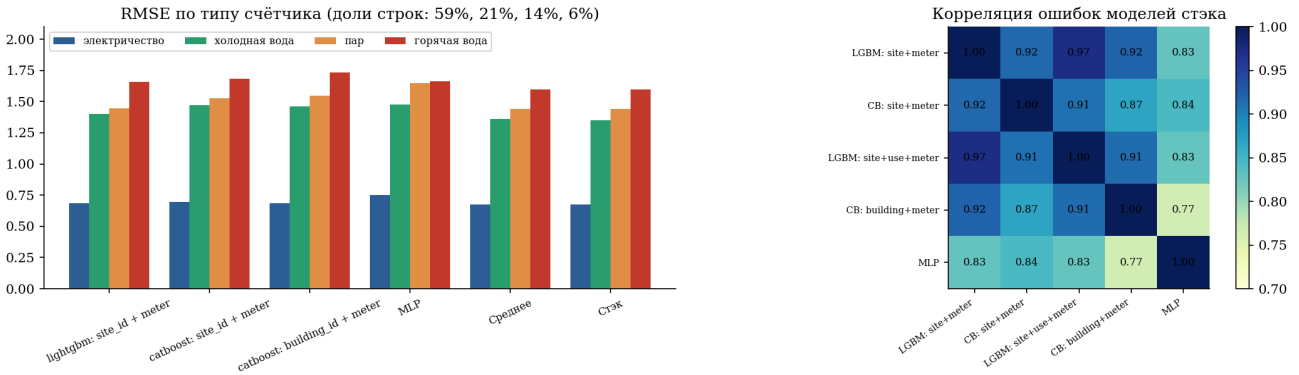


Рис. 5. Слева: RMSE по типу счётчика. Справа: корреляция ошибок моделей стэка.

5. Результаты на Kaggle

Показатель	Значение
Score	1.125
Позиция на private leaderboard	Top 29%

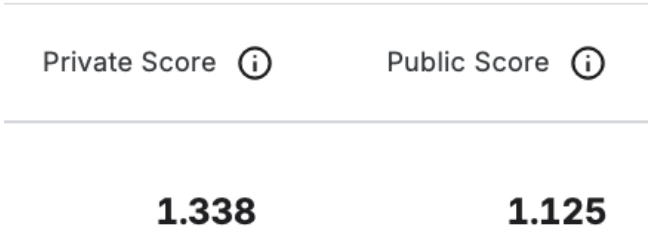


Рис. 6. Результат на Kaggle.

Версия 3 улучшила результат за счёт нескольких одновременных изменений (сырая погода, час и день недели, чистка обучения, окно температуры 72 часа, ограничение прогноза); по отдельности на Kaggle они не мерились. Итоговая версия из репозитория (месяц, праздники, окна температуры, валидация блоками, стэк из 5 моделей) дала **Public 1.145 / Private 1.381 — хуже версии 3 (1.125 / 1.338)**, хотя на локальных блоках выглядела лучше. Какое из изменений виновато, по одной отправке сказать нельзя; главный подозреваемый — признак month (гипотеза: отправка без него не делалась).

Результаты берутся с Kaggle через CLI (история отправок и весь private leaderboard); сохранённые копии — в results/.

6. Выводы и ограничения

Выводы

1. Главная трудность — не точность подгонки, а перенос на другие годы: проверка внутри 2016 года завышает качество (1.00–1.05 против 1.34 на private), поэтому её значения годятся для сравнения моделей, но не как прогноз результата.

2. Дешёвые решения оказались не хуже дорогих: LightGBM по типу счётчика за 0.4 мин лучше всех одиночных моделей; подбор параметров (около часа) и CatBoost глубины 10 не окупились.

3. Разнообразие ансамбля важнее весов: простое среднее почти не уступает Ridge. Добавлять надо модели другого типа.

4. Ошибка сосредоточена на тепловых счётчиках (две трети квадратичной ошибки при 41% строк).

Ограничения и риски

• Один год обучения: эффект месяца и праздников не проверяем без второго года. • Отдельный вклад признаков на Kaggle не измерен (изменения отправлялись пакетом). • Часть объяснений (число строк на модель, структура деревьев CatBoost) — предположения, прямо не проверялись. • Общие модели по meter в тестовой схеме (площадка за площадкой) пока не реализованы. • Прогноз ограничен максимумом train: 9 строк выше, в основном здания 791–803 на площадке 7 около 30.10.2017.

Что делать дальше

Отправить версию итогового стэка без месяца (и без праздников), чтобы проверить подозрение; добавить в стэк общие LightGBM по типу счётчика; убрать CatBoost глубины 10; добавить модель другого типа.

Воспроизведение: см. README.md. Ноутбук research.ipynb, данные и ключи Kaggle в репозиторий не входят.